

Module 1

Projet 1 - Data&BI

Fraude aux paiements mobiles

Le Problème

Besoin métier

De l'argent est détourné par des transferts suivis de retraits sur des comptes mobile money.

Décision

Autoriser ou bloquer la transaction.

Cible

isFraud : transaction frauduleuse (1) ou légitime (0).

Unité d'analyse

une transaction

Moment de la prédiction

Avant l'exécution, avec les seules infos connues à cet instant.

Critère de succès

-50 % de montant fraudé, moins de 1 % de transactions légitimes bloquées à tort.

Les Données

6,36 M

transactions (= lignes)

11

colonnes, 8 gardées

0,13%

de fraudes (8213)

744h

soit 1 mois simulé

Source principale

Paysim : Synthetic Financial Datasets For Fraud Detection

Kaggle (CSV) - Jeu Synthétique:

<https://www.kaggle.com/datasets/ealaxi/paysim1/data>

Granularité: une ligne = une transaction. La colonne step compte les heures simulées.

Cible: 'IsFraud'

Licence: CC BY-SA 4.0, citer Lopez-Rojas et al. (2016).

Source complémentaire

Rapport annuel - OSMP 2025 (évaluée selon les 7 critères)

Banque de France (PDF/XLSX)
Statistiques agrégées sur la fraude
Contextualisé Paysim
Pas de jointure avec Paysim

Retirées du jeu de modélisation :

newbalanceOrig et newbalanceDest, connus seulement après la transaction, et isFlaggedFraud, sortie d'une règle déjà en place. Le jeu brut reste intact.

Sources rejetées

Raison

Données réelles

Confidentielles, aucun accès

MoMTSim

Autre jeu synthétique, faible valeur ajoutée

Communiqué OSMP S1 2025

Moins complet que le rapport annuel

Les Risques

Fuites de données

- newbalanceOrig/Dest : connus après la transaction
- isFlaggedFraud : copie d'une règle existante
- Identifiants de comptes exclus des variables
- Découpage temporel sur step, jamais aléatoire

Biais

- Calibré sur un opérateur, un pays, un mois (données synthétiques)
- Un seul scénario : transfert puis retrait
- 0,13 % de fraude : l'accuracy trompe
- Mesurer rappel, précision et montant sauvé

Données Personnelles

- PaySim : comptes fictifs, personne de réel
- En réel : données personnelles, donc RGPD
- Blocage automatique : recours humain prévu
- Accès restreint et durée de conservation fixée

Limites

- Synthétique : résultats non transférables
- Un seul mois, aucune saisonnalité
- Pas d'appareil, de lieu ni d'historique client
- Les fraudeurs s'adaptent : réentraîner