{EPITECH}

PROJET PAYSIM

MODULE 2

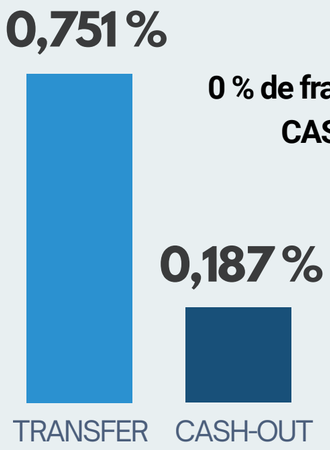
Fraude aux paiements mobiles

AYMEN FENINICHE - SELENA FERSAOUI - YASMINE GHEDDAB - KALIL MEDFAI - GLENN TCHAMAGAM - MARIAM SYLLA

1. Ce que disent les données

6 362 620 transactions | **8 213** fraudes (0,1291 %) | **Échantillon EDA** 500 000 lignes, dont 645 fraudes

H1 — Type de transaction: confirmée, effet faible

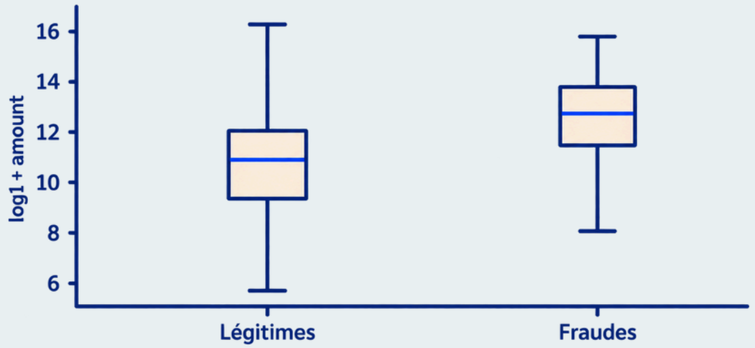


0 % de fraude pour PAYMENT, CASH_IN et DEBIT

$p \leqslant 5\times10^{-5}$ (limite du Monte-Carlo)
V de Cramér= 0,0578 • IC [0,05 ; 0,06]

H2 — Les montants: confirmée, effet fort

80,6 % → de probabilité qu'une fraude ait un montant plus élevé qu'une transaction légitime

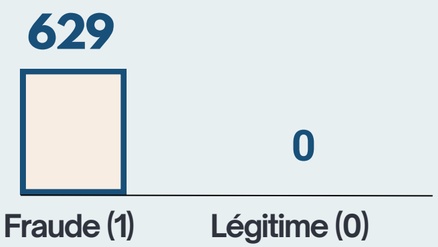


Mann-Whitney bilatéral • p Holm = $2,96 \times 10^{-159}$
Taille d'effet r = 0,6122 • IC 95 % [0,6 , 0,6]

H3 — Montant = solde initial : confirmée, séparation quasi parfaite

Fraudes contre transactions légitimes
Condition : solde > 0 ; écart ⩽ 0,01

38,10 millions
OR corrigé (+0,5)



• **probable règle du simulateur**

629 transactions → 97,5 % des fraudes (629 sur 645)

Fisher bilatéral • p < précision numérique
IC [2,3 M , 635,8 M]

Contrôle SQL:

→ **Le volume de transactions s'effondre les jours 3-5 et dès le jour 18 alors que les fraudes restent stables, autour de 270 par jour**
→ **0 doublon**
→ **Artefact de simulation : step uniquement pour le découpage**

2. Le modèle de référence

Régression logistique (baseline) • **Seuil retenu : 0,98** (au plus **1 %** de transactions légitimes bloquées)

Découpage chronologique

Période	Steps	Lignes	Fraudes
Entraînement	1-281	335 288	617 - 0,18%
Validation	282-354	109 304	136 - 0,12%
Test réservé	355-743	110 516	843 - 0,76%

Préparation des données et pipeline scikit-learn

- 6 Variables : type, amount, oldbalanceOrg, oldbalanceDest, nb_tx_orig_avant, nb_recu_dest_avant.
- Imputation et standardisation des 5 variables numériques, one-hot de type
- class_weight="balanced"

Le périmètre :
TRANSFER et CASH_OUT
échantillon de 20 %
(555 108 lignes)

Validation - 109 304 transactions
Résultats au seuil de 0,5

Indicateur	Naïf	Régression
Rappel	0%	83,82%
Précision	0%	1,31%
F1 - Score	0%	2,58%
Accuracy	99,88 %	92,11%
PR-AUC, IC 95%	0,0012	0,126 IC [0,080 ; 0,194]

Le seuil qui respecte la limite de 1 % est d'environ **0,98**, sur la validation.
Il donne **1 139 alertes**, un rappel de **36 %** et une précision de **4,3 %.**

> **Au seuil de 0,5 : 114 fraudes détectées sur 136 (83,82 %), mais 8 604 transactions légitimes bloquées à tort (7,9 %).**

3. Ce qui reste à faire

01 — Limites

- Données **synthétiques** et **cible rare**
- **H3** peut refléter une règle du simulateur.
- **Les IC** supposent des transactions indépendantes
- **Le taux de fraude** du test (**0,76 %**) est six fois plus élevé que celui de la validation → **(0,12 %)**

02 — Fuites évitées et vigilance

- **Soldes** post-transaction et isFlaggedFraud exclus
- **nameOrig et nameDest** ne sont pas utilisés comme variables.
- **Step** réservé au découpage
- **Variables SQL calculées** sur les steps des historiques précédents
- **Prétraitements** appris sur l'entraînement uniquement

03 — Pistes module 3

- Revoir **le seuil** avec un coût par fraude et par alerte.
- **Un modèle non linéaire** (forêt aléatoire ou boosting), puisque la régression reste faible.
- Traiter **les soldes à 0** (probables faux codes)

{EPITECH}

MERCI